SK 네트웍스 Family AI 34기 : 3팀

수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
제출 일자	2026. 10. 23.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN34-FINAL-3TEAM
작성 팀원	황수빈

수집 데이터

1. 수집 데이터 개요

- 본 보고서는 사고뭉치의 사업성(BM) 및 시장 분석에 활용하는 데이터를 대상으로 하며(모델 학습·평가용 AI Hub 데이터는 모델 파트 수집 데이터 보고서에서 별도 기술), 공공 통계, 공식 웹페이지, 언론 보도의 공개 수치만 활용하고 전 지표를 원출처와 대조하여 확인 상태(일치·수정·미확인·삭제)를 표기함

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
초중고 사교육비조사 (2025)	사교육비 총액, 학교급별 참여율·월평균, 일반교과·논술 지출	시장 현황, TAM·SAM 산정, 가격 기준점	기획서 3.1·3.3·3.7	국가데이터처 보도자료 원문, 정책브리핑, 언론 보도
교육기본통계 (2026), 학생 수 추계	초·중·고 학생 수, 초1 입학생 수	초3~6 학생 수, TAM·SAM·SOM 산정	기획서 3.1·3.3	교육부·한국교육개발원 공개 통계
경쟁·대체 서비스 가격	써봄, 밀크T 초등, 아이스크림 홈런 초등 요금	가격 기준점	기획서 3.4·3.7	각 사 공식 결제 페이지(2026-10-23)
독서논술 학원 교습비	한우리·리드인·리딩엠 지점별 등록 교습비	가격 기준점, 학원 채널 판단	기획서 2.4·3.4	NEIS 학원교습소정보(교육청 등록, 2026-10-23)
학원 공급 통계	전국 사설학원 수, 수강인원, 서울·경기 비중	B2B2C 채널 규모, 초기 영업 지역	기획서 3.8	한국교육개발원 교육통계연보
학생·학부모 인식 조사	학생 AI 사용 실태, 학부모 AI 숙제 인식, 학원 앱 AI 활용 의향	문제 정의, 결제 이유, B2B2C 근거	기획서 2장·3.6·3.8	교육청 연구 보고, 언론 보도(조사 주체·표본 병기)

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
정책·공공·확장 근거	2022 개정 총론, 하이러닝 이용 건수, 교육부 예산, 약술형 논술, PIAAC	문제 정의, B2G 판단, 확장 단계 근거	기획서 2장·3.1·3.2	교육부 고시, 교육청·OECD 공개 자료, 언론 보도
원가 기준 자료	LLM API 단가, 결제 수수료, 환율	1인당 원가 산정	기획서 3.9	Anthropic 가격표, 토스페이먼츠, 언론 보도
자체 측정 데이터 (예정)	LLM 호출별 토큰 수, 리포트 직접 작성 대비 자동 검토 시간	1인당 원가, 업무가치 ROI 실측	기획서 3.5·3.9	자체 생성(가상 학생, 측정자 비식별)

2. 수집 방법 및 자동화 절차

2.1 수집 방식 (해당 항목에 체크)

수집 방식	선택	수집 방식	선택
웹 크롤링	☐	API 호출 (NEIS 학원교습소정보 오픈 API, 샘플 조회)	☑
사용자 입력 (팀원 업무 시간 측정 기록, 예정)	☐	문서 파일 (국가데이터처 보도자료 PDF 통계표)	☑
기타: 공개 자료 조사 및 원출처 대조(통계 보도자료, 공식 결제 페이지, 언론 보도)	☑		

2.2 수집 도구 및 자동화

사용 언어 / 라이브러리	웹 검색 및 브라우저 기반 원출처 수동 확인 NEIS 오픈 API 조회(브라우저 JavaScript fetch), 등록 교습비 중앙값 산출 Python(표준 라이브러리) 기반 시장 규모 산출, matplotlib 기반 시각화 Markdown 정리 문서(사고뭉치_BM_정리.md) 관리
자동화 여부 및 주기	공개 자료: 1회 수집 후 확인일 기록, 가격 확정 시점 재확인 NEIS 교습비: 키 없는 샘플 조회(요청당 5건)로 지역·브랜드별 표본 수집, 인증키 발급 후 전수 조회 예정 LLM 사용량(예정): 시연 시 호출 단위 자동 기록 업무 시간(예정): 12/7 이전 1회 측정(측정자 2명)
오류 발생 시 예외 처리 전략	원출처와 불일치 시 원출처 값 채택 및 [수정] 표기 미확인 값은 [미확인] 표기 후 가정 시나리오에만 활용 근거 미확보 주장은 문서에서 삭제(예: 2027 에듀테크 예산 감소) 접근 제한 사이트는 우회 없이 대체 공식 출처 활용 교습비 미공개 지점은 집계에서 제외하고 공개 지점 수를 함께 표기

2.3 예시 스크립트 또는 흐름도 첨부

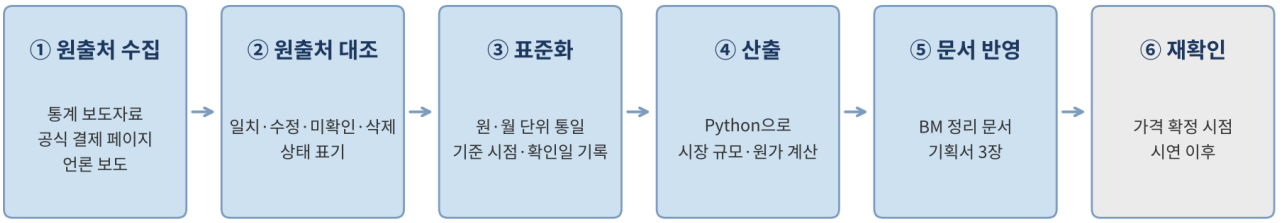


그림 1. BM 데이터 처리 흐름 (원출처 수집 → 대조 → 표준화 → 산출 → 문서 반영 → 재확인)

3. 데이터 설명 및 구성

3.1 수집 지표 목록 (파일 및 필드 설명)

지표	값	기준 시점	출처	확인 상태
초등 사교육비 총액	12조 1,744억 원	2025년	2025 사교육비조사(언론 보도, 정부 원문은 12.2조로 반올림)	일치
초등 사교육 참여율	84.4%	2025년	정책브리핑 원문	일치
초등 참여학생 월평균 사교육비	51만 2천 원	2025년	정책브리핑 원문	일치
참여학생 월평균 사교육비(전체)	60만 4천 원	2025년	2025 초중고 사교육비조사	일치
사교육비 총액 및 증감	27조 5,351억 원, 전년 대비 -5.7%	2025년	2025 초중고 사교육비조사	일치
일반교과 사교육 참여율	전체 56.5%, 초 56.9%, 중 61.5%, 고 50.5%	2025년	국가데이터처 보도자료 통계표 2	일치
논술 과목 월평균 지출(참여학생, 초중고 전체)	15만 3천 원	2025년	언론 2차 분석(학교급 구분 없음)	일치(2차 자료)
초등학생 수	221만 9,370명	2026. 4. 1.	2026 교육기본통계	일치
중학생 수	133만 8,750명	2026. 4. 1.	2026 교육기본통계	일치
고등학생 수	127만 9,392명	2026. 4. 1.	2026 교육기본통계	일치
초·중·고 학생 수(TAM)	483만 7,512명	2026. 4. 1.	2026 교육기본통계	일치

지표	값	기준 시점	출처	확인 상태
초1 입학생 수(추계)	29만 8,178명	2026학년도	교육부 학생 수 추계	일치
초1 입학생 수	32만 4,040명	2025학년도	교육부 학생 수 추계	일치
초3~6 학생 수(산출)	약 159만 7,152명	2026년	초등 전체 − 초1 − 초2(2025 초1로 근사)	수정(4/6 균등 분할 대체)
SAM(산출)	약 173만 2천 명(초3~6 90만 9천 + 중1~3 82만 3천)	2026년	위 지표로 산출	수정(4/6 균등 분할 대체, 기획서 반영)
SOM(산출)	약 8,700명(SAM의 0.5%), B2C 연 19.7억~30.1억 원 / 전원 학원 경유 시 B2B2C 연 5.2억~10.4억 원	3년 내	위 지표로 산출	수정(4/6 균등 분할 대체, 기획서 반영)
2027 교육부 예산안	117조 5,962억 원(+10.6%)	2027년안	언론 보도	일치
2027 영유아·초중등 예산	82조 1,165억 → 89조 7,354억 원	2027년안	언론 보도	일치
하이러닝 AI 서·논술형 평가	AI 채점 누적 60만 7,145건	2025. 6.~10월 말	언론 보도	일치
써봄 월 요금	개인 9,900원, 교사 29,900원	2026-10-23	공식 구독 페이지	일치
밀크T 초등 월 요금	11만 9천~14만 9천 원(약정)	2026-10-23	공식 결제 페이지	일치
아이스크림 홈런 초등 월 요금	11만 4천~14만 4천 원(약정 정가)	2026-10-23	공식 결제 페이지	일치

지표	값	기준 시점	출처	확인 상태
한우리 초등 기본 과정 교습비	중앙값 월 12만 원(6만 7천~14만 5천 원, 공개 41곳, 주로 주 1회)	2026-10-23	NEIS 학원교습소정보(교육청 등록)	일치(등록값 집계)
리드인 초등 기본 과정 교습비	중앙값 월 15만 원(8만~24만 5천 원, 공개 28곳, 주 2~5회)	2026-10-23	NEIS 학원교습소정보(교육청 등록)	일치(등록값 집계)
리딩엠 교습비	서울·경기 지점 교습비 미공개	2026-10-23	NEIS 학원교습소정보	미확인
독서논술 학원 월 17만~27만 원(리딩엠 도곡 25만, 대구 리드인 17만~19만)	17만~27만 원	2022·2025년	기획서 기존 등록 정보(프롬피)	수정(등록 교습비 중앙값 12만~15만 원으로 대체, 기획서 반영)
학부모 AI 숙제 인식(318명)	찬성 43.7%, 최종 답안 생성 허용 3.8%	2026. 7.	언론 보도((주)깔로 조사)	일치
생성형 AI를 쓰는 10대의 부모 중 자녀 사용을 아는 비율(미국 1,045명)	37%	2024년	언론 보도(Common Sense Media)	일치(해외 자료)
학원 앱 AI 기능 활용 의향(1,204명)	67.9%	2025. 11.	언론 보도(대교에듀베이션 조사)	일치
LLM 토큰 단가	Claude Sonnet 5.5 입력 $2, 출력 $10(100만 토큰당)	2026-10	Anthropic 공식 가격 문서	일치
2027 에듀테크 예산 감소	—	—	근거 미확보	삭제

지표	값	기준 시점	출처	확인 상태
초등 일반교과 참여율 변화	67.1% → 56.9%(-10.2%p)	2024→2025년	교육부 2024·국가데이터처 2025 보도자료	일치(%p 단위 확인)
일반교과 참여학생 월평균	59만 5천 원(+7.9%)	2025년	국가데이터처 보도자료	일치
국어·영어·수학 사교육 참여율	25.4%, 53.4%, 54.1%(전체학생 기준)	2024년	교육부 2024 보도자료(2025년 국어는 20.9%)	일치
국어 참여학생 월평균	18만 5천 원	2025년	국가데이터처 보도자료 표 8	일치
국어 사교육비 총액 증가율	2013년 대비 +84.2%	2013→2025년	언론 2차 분석(괜찮은뉴스)	수정(출처 표기 정정, 기획서 반영)
전국 사설학원 수·수강인원	9만 4,866개(2024년 9만 385개, 2023년 8만 8,738개), 수강인원 674만 5,719명, 서울·경기 학원 수 45.1%·수강인원 57.7%	2025년	성인지통계 DT_1LCC011(한국교육개발원 교육통계연보)	일치
서울 학생 생성형 AI 사용 경험·교사 과의존 우려	94.7%(학생 2만 6,531명), 93.4%(교사 3,344명)	2025. 7. 조사	서울시교육청교육연구정보원(뉴시스)	일치
약술형 논술 지원	지원자 2023학년도 4만 5,586명(8개 대학) → 2026학년도 12만 4,448명(15개 대학)	2023~2026학년도	이투스 분석(뉴시스 2026. 8. 6.)	수정(원출처 확인값으로 대체, 기획서 반영)

지표	값	기준 시점	출처	확인 상태
한국 성인 언어능력(PIAAC 2주기)	249점(OECD 260점), 1주기 대비 -24점	2024. 12.	언론 보도(OECD 발표)	일치
스마트올 초등 월 요금	79,000원~(비관리형 38개월 약정)	—	제3자 정보 페이지	일치(2차 자료)
토스페이먼츠 카드 수수료	3.4%(부가세 별도)	2026-10	공식 요금 페이지	일치
원·달러 환율	1,324.2원(주간 종가)	2026. 10. 22.	머니투데이(기획서 표기 뉴시스는 정정)	일치
2022 개정 총론 평가 문구	"서술형과 논술형 평가의 비중을 확대한다"	2022 고시	총론 원문(2차 확인)	일치(2차 자료)
충북 에듀테크 소프트랩	교사·기업 8개월 효과 분석, 3차년도	2026. 4.	대학저널	일치

예정 데이터 필드: llm_usage_log(call_type, model, input_tokens, output_tokens, ts), time_study(rater, task, minutes), neis_fees(brand, region, academy, course, fee, checked_at)

3.2 데이터 양

전체 수집 데이터 건수	수집 지표 45개(통계·정책, 학생 수, 서비스·학원 가격, 인식 조사, 원가 기준, 산출값 포함), 2026-10-23 기준
추출된 고품질 데이터 건수 (필터링 후 기준)	활용 가능 43개(일치 37, 수정 6), 미확인 1개(가정 시나리오 한정), 제외 1개(삭제)

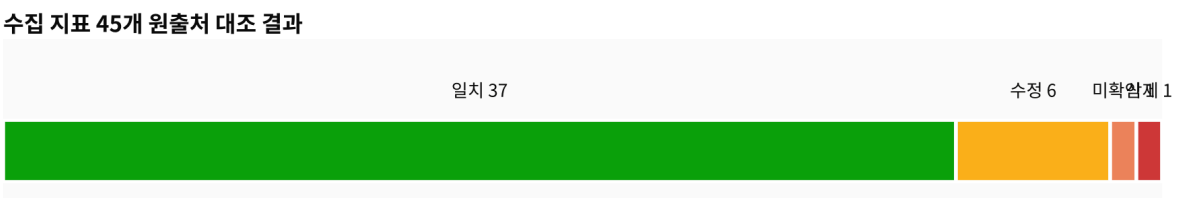


그림 2. 수집 지표 원출처 대조 결과

3.3 저장 위치 및 포맷

저장 경로	정리 문서: 팀 레포 docs/bm/사고뭉치_BM_정리.md (예정) 산출·시각화 스크립트: docs/bm/charts.py (예정) 원출처 확인 기록: 지표별 출처 링크와 확인일(정리 문서 부록) NEIS 교습비 표본: docs/bm/neis_fees.csv (예정) 로그(예정): LLM 사용량 테이블(PostgreSQL)
저장 포맷	☐ CSV ☐ JSON ☐ SQLite ☑ 기타: Markdown, PNG(차트) / 예정: CSV, PostgreSQL
인코딩	☑ UTF-8 ☐ 기타: _____

3.4 수집 데이터 요약 시각화

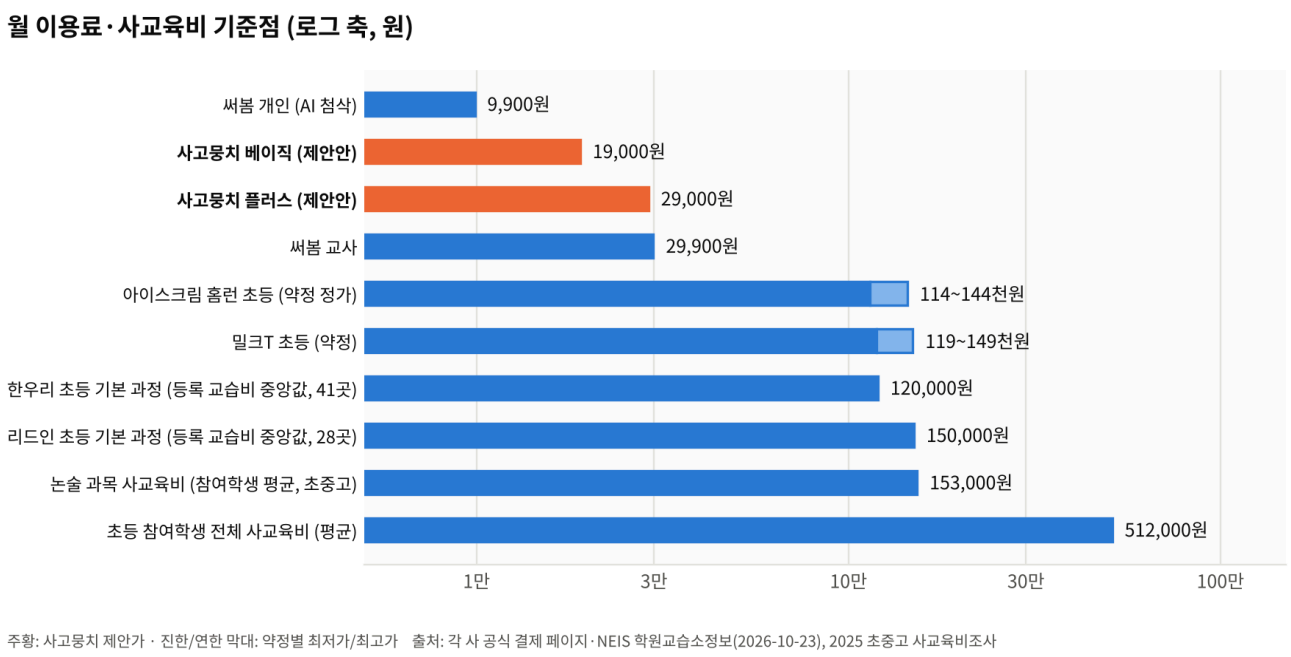
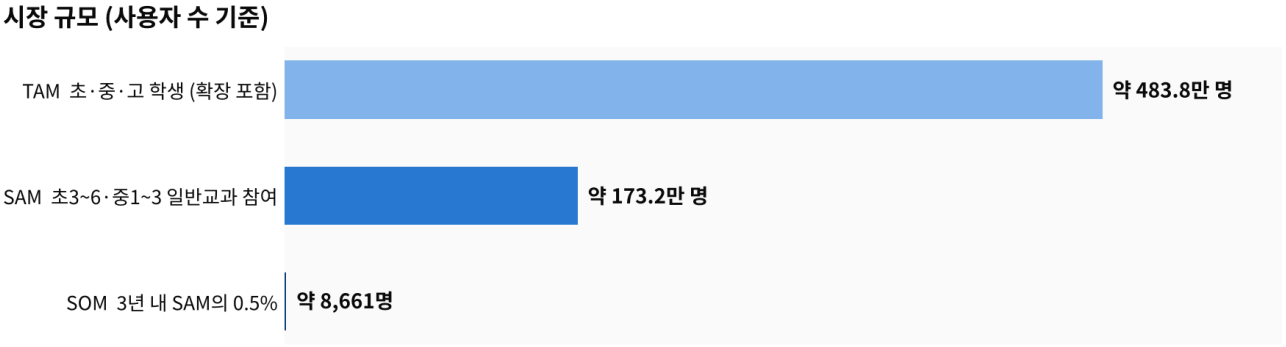


그림 3. 월 이용료·사교육비·학원 교습비 기준점과 사고뭉치 제안가(베이직 19,000원, 플러스 29,000원)



SAM = 초3~6 159만 7,152명 × 56.9% + 중학생 133만 8,750명 × 61.5% (2025 일반교과 사교육 참여율), 초3~6 = 초등 전체 − 초1 − 초2(2025 초1로 근사)
출처: 2026 교육기본통계, 교육부 학생 수 추계, 국가데이터처 2025 초중고사교육비조사 통계표 2

그림 4. 시장 규모 (사용자 수 기준, 초3~6은 학년별 산출값 적용)

4. 법적·윤리적 검토

개인정보 포함 여부	☐ 포함 ☑ 미포함 공개 통계 및 집계 수치만 활용, 개인 단위 데이터 없음
포함된 경우 필드	해당 없음(업무 시간 측정은 팀원명 대신 R1·R2, LLM 로그는 가상 학생 ID만 사용 예정)
비식별화 조치 여부	☐ 이름 마스킹 ☑ 고유키 대체 ☑ 기타: 집계치만 수집, 실제 아동 정보 미수집
출처 및 사용권 — 공개 여부	☐ 공개 ☑ 내부사용 한정 원출처는 공개 자료이나 정리본은 팀 내부 자료로 한정 발표·기획서에는 수치와 출처만 인용
라이선스 / 약관 검토 여부	정부 보도자료·통계: 출처 표기 후 수치 인용 언론 보도: 수치 및 조사 정보만 인용, 기사 본문 전재 없음 경쟁사 웹페이지: 공개 요금만 기록, 화면 원문 재게시 없음 공공 오픈 API: 수집 전 이용 허락 범위 확인(학원·교습소 정보는 제한 없음 표기)
검토자	황수빈
검토 일자	2026-10-23 (팀 검토 전 초안)

5. 데이터 품질 및 정합성 관리 방안

중복 제거 기준	동일 지표가 복수 기사에 보도된 경우 정부 원문(정책브리핑·보도자료) 1건만 채택, 기사는 보조 출처로 관리
정합성 검증 방법	전 수치 원출처 대조 후 확인 상태 표기 산출값(초3~6 학생 수, SAM·SOM, 1인당 원가)은 스크립트로 재산출하여 문서 값과 비교 2차 자료(블로그, 해외 조사)는 출처에 별도 표기
Null 처리 및 결측치 전략	미확인 값은 공란 처리 없이 [미확인] 및 "가정" 표기 후 시나리오 산출에만 활용 근거 미확보 시 문서에서 삭제
표준화 전략	금액은 원 단위·월 기준으로 통일, 가격은 정가와 약정 기간을 함께 기록(이벤트가는 비고 기재) 전 수치에 기준 시점(조사 연도) 및 확인일 기록

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026-10-23	황수빈	초안 작성: 시장·가격·정책 데이터 수집 및 원출처 대조, 초3~6 학생 수 재산출, 근거 미확보 문구 삭제	학원 수, 학년별 통계, 논술 참여율 확보 예정
2026-10-23	황수빈	보완: 3.1을 지표 목록으로 재구성, 미수행 항목 "(예정)" 표기, 시각화 3종 추가	독립 재검증 결과 반영
2026-10-23	황수빈	기획서 최종본 대조: 시장 규모 기준(초중고 TAM, 일반교과 참여율) 반영 및 학년별 보정, 학원 교습비를 NEIS 등록값으로 교체, 가격 제안안·LLM 단가 반영, 기획서 인용 지표 추가 검증	기획서 3.3·2.4·3.4 동일 수치로 반영 완료