SK 네트웍스 Family AI 34기 : 3팀

프로젝트 기획서

산출물 단계	기획
제출 일자	2026. 10. 25.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN34-FINAL-3TEAM
작성 팀원	최성욱

프로젝트 기획

1. 프로젝트 주제
2. 문제 정의
3. 시장조사 및 BM 분석
4. 시스템 구성 기획
5. 모델링 계획
6. 데이터 수집 전략
7. 역할분담(R&R)

1. 프로젝트 주제

사고뭉치 — 아이의 생각이 바뀌는 과정을 기록하고, 그 기록을 학부모가 대화로 분석하는 사고력 학습 플랫폼

과정 공통 주제인 "대화형 데이터 기반 분석 에이전트 및 자동 리포팅 플랫폼"을 초등~중학생 사고력 학습에 적용함

한 문장	AI가 대신 써 주는 시대에, 생각은 아이가 직접 하게 만드는 서비스
사용자	학생 **초1~중3** (초1~2는 고르기·말하기 중심, 초3부터 서술형·논술형) → 추후 확장: 고등학생 논술 평가, 성인 논술·작문
결제자	학부모 (B2C 월 구독) → 추후 B2B 유통 예정
핵심 경험	미션을 풀며 생각 작성 → 사고뭉치가 아이의 말을 짚어 되물음 → 한 걸음 더 생각 → 정답·예시 답 확인 및 돌아보기
데이터 분석 에이전트	학부모가 "질문을 받고 뭐가 달라졌어?"처럼 질문하면 에이전트가 학습 기록을 도구로 조회·계산해 답변하고, 답변 속 숫자·인용은 실제 기록과 자동 대조함
자동 리포팅	주간 생각 리포트를 기록에서 자동 생성(숫자 근거(분모·계산식 포함), 다섯 가지 생각 유형, 질문 전후 변화, 아이의 돌아보기)
다루는 생각	다섯 가지 생각 유형(분석하기·따져 보기·새로 만들기·문제 해결하기·돌아보기)과 그 바탕인 기초 사고력(비교·분류·순서·규칙·원인과 결과·추론)

사고뭉치는 글 대필이나 맞춤법 교정 서비스가 아니며, 사고력 진단 검사나 성적 향상 보장 서비스도 아님

숫자 레벨은 검증 전까지 학생·학부모에게 공개하지 않음

2. 문제 정의

2.1 현상: 무엇이 바뀌고 있나

현상	근거	출처
학교 평가가 "결과"에서 "생각 과정을 쓰는 것"으로 변경	2022 개정 총론: "서술형과 논술형 평가의 비중을 확대한다", "문제 해결 및 사고의 과정을 중시하는 평가"	교육부 고시 제2022-33호 [별책 1] 초·중등학교 교육과정 총론 (국가교육위원회 고시 제2026-1호 일부개정 포함, 2026.1.21.)
생성형 AI가 학생 글쓰기에 사용	서울 중·고생 생성형 AI 사용 조사	서울시교육청교육연구정보원 「생성형 AI의 교육적 활용 실태 및 요구 조사 연구」(2025.7. 조사, 2026.1.11. 발표) / 뉴시스 보도
기초 문해력 저하 신호	국가수준 학업성취도 평가 국어 1수준(매우 낮음) 비율: 중3 10.1% → 10.8%, 고2 9.3% → 10.4%(2024 → 2025, 통계적으로 유의미한 변화는 아님)	교육부·한국교육과정평가원 국가수준 학업성취도 평가 결과(중3·고2 약 3% 표집) / 헤럴드경제(2024 결과), 2025 결과 보도
서술형·논술형 피드백 수요가 증가	경기도교육청 하이러닝 AI 서·논술형 평가가 2025년 7월 개통(6월 공개 시연) 후 10월 말까지 누적 60만 7,145건 사용	교육을 비추다
학부모의 교육비 부담이 역대 최고	2025년 초중고 사교육비 총액 27조 5천억 원, 사교육을 받는 학생 1인당 월평균 60만 4천 원(역대 최고)	교육부·국가데이터처 2025년 초중고 사교육비 조사 / 뉴시스
학부모는 AI가 답을 대신 쓰는 것에 반대	중·고생 학부모 318명 중 AI 활용 찬성 43.7%, 최종 답안·결과물 생성 허용은 3.8%	(주)깔로 조사(2026.7.22.~29.) / 한국경제TV 보도(2026.8.6.)
학부모는 자녀의 AI 사용을 잘 모름	미국 조사에서 생성형 AI를 쓴 10대의 부모 중 37%만 자녀의 사용을 알고 있었음(부모 1,045명, 해외 자료)	Common Sense Media 「The Dawn of the AI Era」(2024.9.18.)

2.2 원인: 왜 문제가 생기나

1. **학습 도구가 정답 중심**

   많은 학습 앱은 정답 여부만 채점하므로 아이가 "왜 그렇게 생각했는지"는 기록으로 남지 않음

2. **서술형 피드백에 많은 인력이 소요됨**

   서술형·논술형 답안은 한 편씩 읽고 피드백을 작성해야 하므로 교사가 모든 학생에게 자세한 피드백을 제때 주기 어려움

   경기도교육청 AI 서·논술형 평가 도입 후 약 4개월(2025년 7월~10월 말) 만에 누적 60만 7,145건이 사용되어 서술형 피드백 수요가 큼을 보여 줌

3. **AI 도구가 생각을 대신함**

   생성형 AI가 답이나 글을 대신 작성하면 아이가 스스로 이유를 만들고 고쳐 보는 단계가 사라짐

   서울 학생의 94.7%가 생성형 AI 사용 경험이 있고, 교사의 93.4%가 학생의 과의존을 우려함

2.3 영향: 누가 어떻게 손해를 보나

대상	영향
학생	이유를 설명하고 피드백받아 고쳐 쓰는 연습이 부족해서 서술형·논술형 평가에 약해질 수 있음
학부모	점수만 보이고 아이가 스스로 썼는지 AI로 썼는지, 생각이 자랐는지 알 수 없어 사교육에 기대게 될 수 있음 (사교육 참여 학생 월평균 60만 4천 원, 역대 최고)
교사·학교	서술형 채점·피드백 부담이 큼

2.4 기존 해결책의 한계

기존 해결책	한계
AI 첨삭 (써봄, 키위런)	완성된 글을 채점하고 고쳐 줌 → 생각 과정이 아닌 결과물을 평가하며, 학부모용 과정 정보는 확인되지 않음
독서·논술 학원	월 12만~15만 원대(주요 프랜차이즈 등록 교습비 중앙값), 시간과 지역 제약
학교 AI 평가 (하이러닝)	학교 수업·평가용으로, 가정·학부모용 기능은 확인되지 않음
일반 생성형 AI	답을 대신 써 줄 수 있어 스스로 생각하는 단계를 건너뛰게 할 수 있음

2.5 핵심 문제

초1~중3 학생이 자기 생각을 이유와 함께 쓰고 피드백을 받아 고쳐 보는 경험을 집에서 반복할 수단이 없으며, 학부모는 그 과정을 근거와 함께 확인할 수 없음

해결 질문: 어떻게 하면 AI가 답을 대신하지 않고 아이가 스스로 생각을 넓히게 하면서, 그 과정을 학부모가 숫자와 아이의 실제 문장으로 확인하게 할 수 있을까?

2.6 범위

- **서비스 대상:** 초1~2 고르기·말하기 기초 사고력, 초3~중3 서술형·논술형과 다섯 가지 생각 유형
- **12/7 구현 범위:** 미션 35개 = 초3~중3 서술형·논술형 30개(다섯 가지 생각 유형 × 학년군 3개(초3~4·초5~6·중1~3) × 2개) + 초1~2 고르기·말하기 시범 5개(유형별 1개), 최소 64개까지 확장은 12/7 이후
- **추후 확장:** 고등학교 논술 평가, 성인 논술·작문
- **제외:** 성적 향상 보장, 대신 써 주기, 맞춤법 교정, 사고력 진단 검사

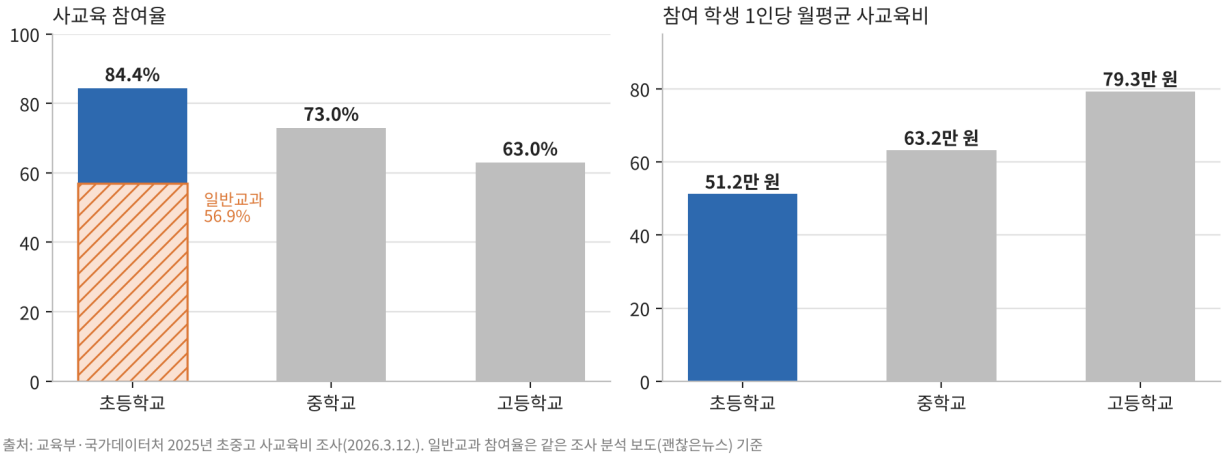
2.7 해결됐다고 볼 기준

기준	지표
아이 스스로 생각을 보완함	처음 답 충족률, 되묻기 후 보완률, 근거·까닭 연결어 변화 (5.3)
논술다운 글을 작성함	논증 요소(주장·근거·반론) 충족률, M2 논술 점수 8개 항목 (5.3)
피드백을 신뢰할 수 있음	사람-AI 일치도: 생각 유형 판정은 카파 계수, M2 점수는 QWK
학부모가 학습 과정을 이해함	리포트 숫자·인용 자동 대조 통과율, 학부모 인터뷰

3. 시장조사 및 BM 분석

3.1 시장 현황

항목	내용	출처
학부모 교육비 지출	2025년 초중고 사교육비 총액 27조 5천억 원, 사교육 참여 학생 1인당 월평균 60만 4천 원으로 역대 최고, 초등 총액은 12조 1,744억 원	교육부·국가데이터처 2025년 초중고 사교육비 조사(2026.3.12.)
학교급별 참여	사교육 참여율 초 84.4%, 중 73.0%, 고 63.0%, 참여 학생 월평균은 초 51만 2천 원, 중 63만 2천 원, 고 79만 3천 원	같은 조사
교과 사교육 참여	일반교과(국·영·수·사·과·논술 등) 참여율은 전체 56.5%, 초 56.9%, 중 61.5%, 고 50.5%로 초등은 2024년 대비 10.2%p 감소, 반면 참여 학생의 일반교과 월평균은 59만 5천 원으로 7.9% 증가	같은 조사, 괜찮은뉴스 분석(2026.3.18.)
국어·논술 사교육	2025년 과목별 사교육 참여율은 수학 47.4%, 영어 46.8% 다음으로 국어 20.9%(2024년 25.4%), 논술은 9.9%(초등 15.5%), 참여 학생 월평균은 국어 18만 5천 원·논술 15만 3천 원, 국어 사교육비 총액은 2013년 대비 84.2% 증가(2025 기준)해 일반교과 중 증가율이 가장 높음	국가데이터처 2025 초중고사교육비조사 보도자료(과목별 참여율, 2024 국어는 교육부 2024 보도자료), 괜찮은뉴스 분석(증가율)
학원 공급	2025년 전국 사설학원 9만 4,866개로 2023년(8만 8,738개) 대비 6.9% 증가, 수강인원 674만 5,719명(서울 195만, 경기 194만), 예체능·성인 대상 학원 포함 수치	한국교육개발원 「교육통계연보」
학생 수	2026년 초등학생 221만 9,370명(전년 대비 5.4% 감소), 초·중·고 학생 483만 7,512명	교육부·한국교육개발원 2026년 교육기본통계(2026.8.26.)
학생의 AI 사용	서울 학생 26,531명 중 94.7%가 생성형 AI 사용 경험이 있고, 교사 93.4%가 과의존을 우려함	서울시교육청교육연구정보원(2026.1.11. 발표)
학교 평가 변화	"서술형과 논술형 평가의 비중을 확대한다"	2022 개정 교육과정 총론
공공 에듀테크	충북 에듀테크 소프트랩은 교사와 기업이 8개월간 제품의 학업 성취도·수업 참여도 효과를 분석함(2026년 3차년도)	대학저널(2026.4.9.)



출처: 교육부·국가데이터처 2025년 초중고 사교육비 조사(2026.3.12.). 일반교과 참여율은 같은 조사 분석 보도(괜찮은뉴스) 기준

그림 1 학교급별 사교육 참여율과 참여 학생 월평균 사교육비 (2025)

시사점: 학부모는 이미 교육에 큰 비용을 지출하고 있으며 교과 사교육 참여 학생의 지출은 오히려 증가함 학생 수 감소에도 학원 수는 늘어 교과 학습 공급처는 많으나, AI 시대에 "아이가 직접 생각했는지"를 확인해 주는 서비스는 3.4 경쟁 서비스 분석에서 찾지 못했으며, 학교 평가는 서술형·논술형으로 전환 중임 생각 과정을 기록해 보여 주는 서비스의 진입 여지가 여기에 있음

3.2 타겟

구분	대상	이유
핵심 타겟	초1~중3 자녀를 둔 학부모	초) 학교급 중 사교육 참여율(84.4%)이 가장 높음, 초1~2는 고르기·말하기, 초3부터 서술형 글쓰기 시작 중) 일반교과 사교육 참여율(61.5%)이 학교급 중 가장 높고, 서·논술형 평가가 내신에 반영되는 시기
추후 확장 1단계	고등학생 논술 평가	고등학생 논술 평가 - 약술형 논술 지원자가 2023학년도 4만 5,586명(8개 대학)에서 2026학년도 12만 4,448명으로 증가하고 실시 대학은 2027학년도 16개교로 확대(이투스 교육평가연구소 분석), 데이터와 채점 기준 확보 후 진행
추후 확장 2단계	성인 논술·작문	성인용 논술·작문 학습 - 한국 성인의 언어능력은 249점으로 OECD 평균(260점)보다 낮고 10여 년 전 1주기 조사 대비 24점 하락(OECD 국제성인역량조사 PIAAC 2주기, 2024.12 발표), 성인은 본인이 결제하므로 학부모 리포트 대신 본인용 성장 리포트로 전환하고 기업 교육(B2B)도 함께 검토

3.3 시장 규모

구분	산식	인원	연 매출 규모(B2C 구독가 기준)
TAM 전체 대상	2026년 초·중·고 학생 수 (확장 단계 포함)	483만 7,512명	1조 1,030억 ~ 1조 6,835억 원
SAM 핵심 타겟	초등: 221만 9,370명 × 56.9%(초등 일반교과 참여율) ≈ 126만 3천 명 중등: 133만 8,750명 × 61.5%(중학교 일반교과 참여율) ≈ 82만 3천 명	약 208만 6천 명	4,756억 ~ 7,260억 원
SOM 3년 내 목표	SAM의 0.5%	약 1만 400명	23.8억 ~ 36.3억 원

※ 연 매출 = 인원 × 월 19,000원(베이직)~29,000원(플러스) × 12개월

※ 학원 경유(B2B2C) 매출은 학생당 월 5천~1만 원으로 별도 산정하며 위 금액에 포함하지 않음, SOM 약 1만 400명이 모두 학원 경유일 경우 연 6.3억~12.5억 원(B2C 23.8억~36.3억 원 대비 약 1/3 수준)

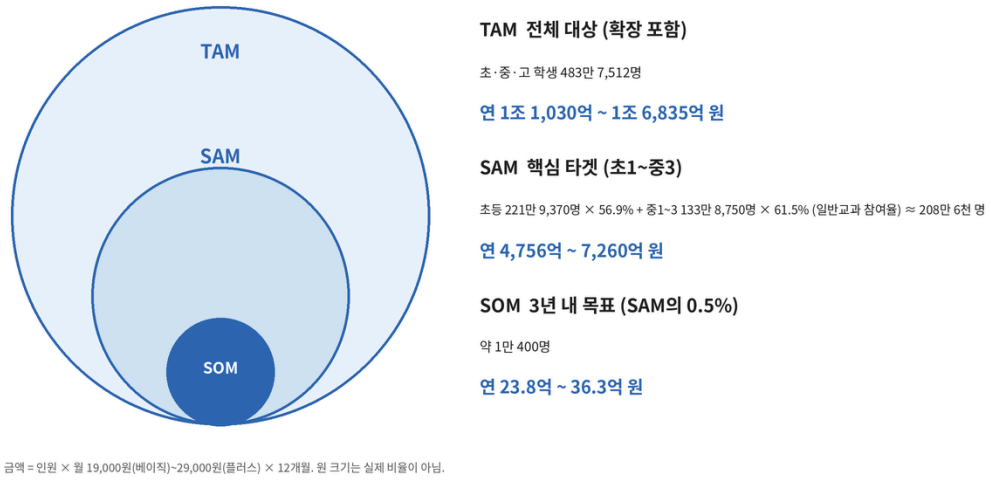


그림 2 TAM·SAM·SOM (원 크기는 실제 비율이 아님)

3.4 경쟁 서비스 분석

서비스	확인한 내용	가격	사고뭉치와의 차이
키위티·키위런 (투블럭AI)	학생 글의 문법·논리 흐름·근거를 평가하고 피드백 제공, 2024년 대교 솔루니에 학생 6,000명·교사 300명 규모로 공급	학교·기관 공급	완성된 글을 평가·수정함 사고뭉치는 아이의 원문과 되묻기 전후 변화로 직접 생각하고 고친 흔적을 학부모에게 제시함
써봄	AI 논술 첨삭, 논리구조·근거타당성·언어표현 3영역 평가	개인 월 9,900원 교사 월 29,900원 (2026.10.23. 공식 구독 페이지 확인)	첨삭과 점수를 제공함 사고뭉치는 답을 고쳐 주지 않고 되묻기로 아이가 스스로 보완하게 하며, 학부모 대화형 분석과 "이번 주 저녁 질문"을 제공함
경기 하이러닝 AI 서·논술형 평가	2025년 7월 개통(6월 공개 시연), 10월 말까지 누적 60만 7,145건	공교육 무료	학교 수업·평가용이며, 사고뭉치는 가정 학습과 학부모 확인용임
독서논술 학원	교육청 등록 교습비(NEIS, 2026.10.23) 초등 기본 과정 중앙값: 한우리 12만 원(41곳), 리드인 15만 원(28곳), 리딩엠 미공개	월 12만~15만 원대	사람이 1:1로 지도함 사고뭉치는 학원과 경쟁하지 않고 숙제·학부모 리포트 도구로 협력함



그림 3. 포지셔닝 맵 (공개 자료로 본 정성 비교)

포지셔닝: 기존 서비스는 결과물(완성된 글)을 채점하거나 사람이 직접 지도함

사고뭉치는 생각의 과정(원문 → 되묻기 → 보완)을 기록하고, 그 기록을 학부모에게 증거와 대화거리로 전달함

3.5 서비스의 세 가지 가치

구분	대상	가치
사용 가치	학생	기존 숙제를 대신하는 짧은 미션, 틀렸다는 지적 없이 되묻기로 한 걸음 더 생각할 기회, 생각 조각 성장 지도로 자기 생각이 자라는 것을 직접 확인
사용 가치	학부모	아이가 쓰고 고친 과정을 원문 근거로 확인, 아이와 나눌 대화거리
업무 가치	학원	학생별 상담 자료·주간 피드백 자동 작성
업무 가치	서비스 운영	서술·논술 1차 채점 자동화
사업 가치	기업	구독 매출, 학원 유통 채널, 생각 기록 데이터 자산

3.6 학부모가 결제하는 이유

- **아이가 직접 생각하고 고친 흔적 확인 (대필 문제 대응):** 리포트에 아이의 원문, 되묻기 전후의 변화(근거 수, 까닭을 잇는 말 수), 쓰기 과정 요약(4.3), 아이 답에 실제로 있는 구절만 인용한 관찰 결과를 제시함
- **아이와 나눌 대화거리 제공:** 주간 리포트마다 "이번 주 저녁 질문"을 제공해 리포트가 읽고 끝나는 문서가 아니라 저녁 식탁 대화로 이어지게 함
- **서·논술형 평가 대비라는 실용적 명분:** 미션을 2022 개정 교육과정 성취기준과 연결해 학교 공부와 연계함

3.7 수익 모델과 가격안 (가설)

상품	가격	구성
베이직	월 19,000원	미션, 되묻기, 주간 리포트
플러스	월 29,000원	베이직 + 리포트에 물어보기(대화형 분석), 이번 주 저녁 질문, 서·논술형 대비 미션
연간 결제	2개월 무료 (약 17% 할인)	이탈 방지

상품	가격	구성
형제 추가	1인당 50% 할인	가구 단위 이용

가격 근거

- **상한 기준:** 사교육 참여 초등학생 1인당 월평균은 51만 2천 원이며 플러스는 그 약 5.7%, 베이직은 약 3.7% 수준, 논술 사교육 참여 학생 월평균(15만 3천 원)과 비교해도 플러스는 약 19% 수준
- **하한 기준:** AI 논술 첨삭(써봄) 개인 월 9,900원, 사고뭉치는 첨삭이 아닌 과정 리포트와 대화형 분석을 제공하므로 그보다 높게 책정
- **검증:** 데모 이후 학부모 가격 민감도 설문과 무료→유료 전환율로 확인 예정, 12/7 배포는 데모 계정만 운영하고 결제는 연동하지 않음

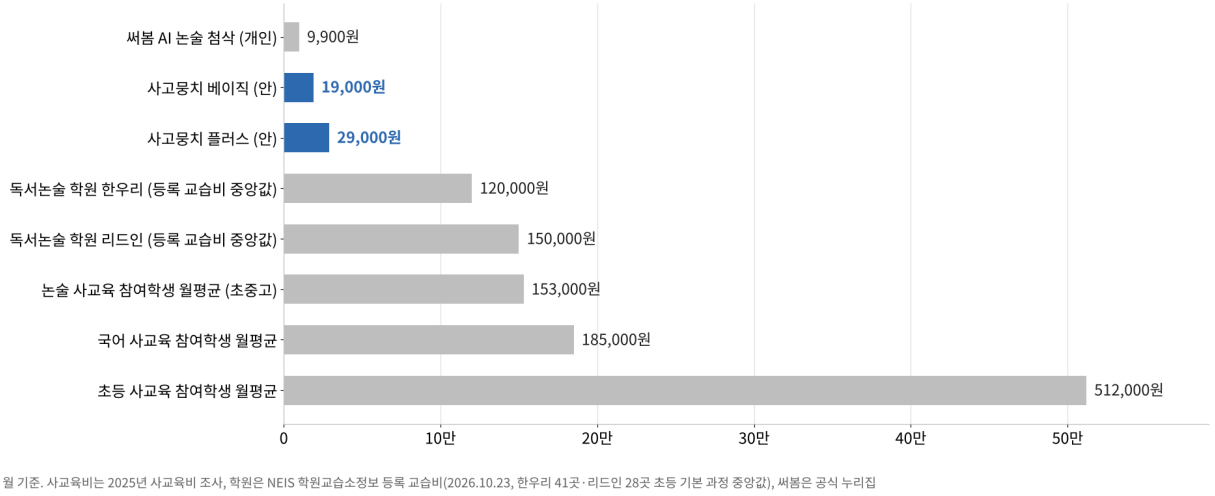


그림 4. 월 가격 비교 (사고뭉치 가격은 제안안)

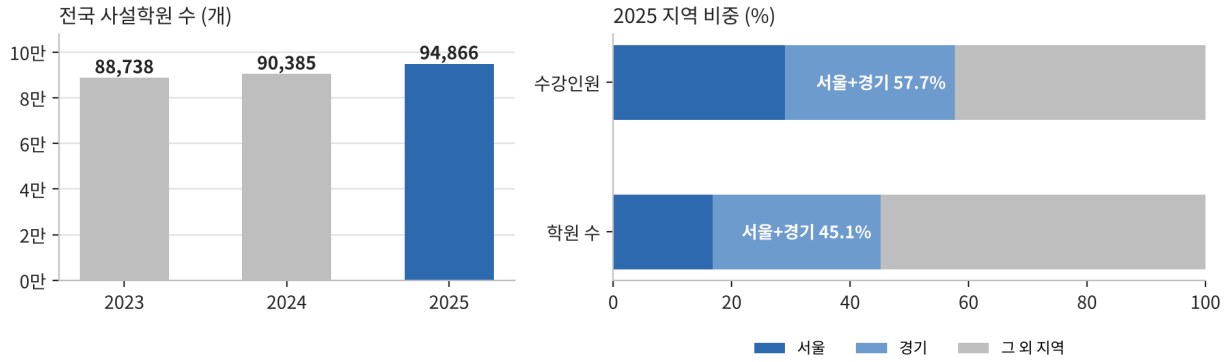
3.8 유통 채널

학원 B2B2C: 학원이 사고뭉치로 숙제를 내고 학부모는 리포트를 받으며, 학원은 학생당 월 5천~1만 원을 부담함

학원을 통하면 여러 학부모에게 한꺼번에 닿을 수 있고 기존 학원과 경쟁이 아닌 협력 구도가 됨

- **채널 규모:** 2025년 전국 사설학원 9만 4,866개, 학생 수 감소에도 학원 수는 2023년 대비 6.9% 증가
- **학부모 수요:** 초·중·고 학부모 1,204명 중 67.9%가 학원관리 앱에 AI 기능이 도입되면 활용하겠다고 응답함(대교에듀베이션, 2025.11.)
- **초기 영업 지역:** 학원 수의 45.1%(4만 2,787개), 수강인원의 57.7%가 서울·경기에 집중되어 있어 수도권 독서논술·국어 학원부터 접근

- **주의:** 이 통계는 예체능·성인 대상 학원을 포함하고 수강인원은 학생 수가 아닌 학원별 인원의 합계이며, 독서논술·국어 학원 수는 별도 확인 필요



출처: 한국교육개발원 「교육통계연보」(성인지통계 DT_1LCC011). 예체능·성인 대상 학원 포함, 수강인원은 학생 수가 아님

그림 5. 전국 사설학원 수와 서울·경기 비중

공공 B2G: 직접 판매가 아닌 실증 사업 참여로 접근하며, 서비스 효과 검증 결과를 공공 시장 진입 경로로 활용 2027 교육부 예산안은 117조 5,962억 원(전년 대비 10.6% 증가)이며 영유아·초중등교육 예산은 89조 7,354억 원임

3.9 원가와 핵심 지표

사용자 1인당 월 LLM 비용 = (미션당 호출 수 × 호출당 토큰 × 월 미션 수 + 대화형 분석 + 주간 리포트 4회) × 토큰 단가

- **단가 기준:** Claude Sonnet 5.5, 입력 100만 토큰당 $2, 출력 100만 토큰당 $10
- **측정:** 토큰 사용량은 서비스에서 호출마다 자동 기록
- **절감:** 리포트와 설명 문장은 주 1회 일괄 생성하므로 실시간 생성보다 비용이 적음

핵심 지표	의미
주간 리포트 열람률	학부모가 가치를 느끼는가
주당 미션 완료 횟수	아이가 꾸준히 쓰는가
학부모 질문 수	대화형 분석이 쓰이는가
무료→유료 전환율	가격이 맞는가
월 해지율	계속 쓰는가 (목표 지표)

3.10 리텐션 전략

- **학생이 계속 쓸 이유:** 숙제를 하나 더 얹는 것이 아니라, 하던 공부를 대신하고 자기 생각이 자라는 것을 직접 보게 함

  ① 숙제 대체: 학원 채널(3.8)에서는 학원이 사고뭉치로 숙제를 내므로 기존 숙제를 대신함 (가정 직접 구독은 주 3회·10분 안팎으로 부담을 제한)

  ② 학교 공부 연결: 미션이 성취기준에 묶여 있어 이번 학기 배우는 단원의 서·논술형 연습이 됨

  ③ 아이가 고름: 같은 생각 유형·학년군의 미션 2개 중 하나를 아이가 직접 고름 (12/7 미션 35개 구성과 맞춤)

  ④ 틀렸다는 말이 없음: 되묻기는 오답 지적이 아니라 "더 말해 볼래?"로 이어지므로 실패감 없이 다시 생각함

  ⑤ 자라는 것이 보임: 생각을 더할 때마다 '생각 조각'이 쌓이는 성장 지도와, 지난 생각을 나란히 보는 돌아보기 (점수·등급·또래 순위는 쓰지 않음)

  ⑥ 가족 대화: 학부모의 '이번 주 저녁 질문'으로 아이의 생각이 대화의 주제가 됨

  애니메이션 미션 장면은 시작 부담을 줄이는 장치로만 쓰고, 친구·경쟁·커뮤니티 요소는 아동 개인정보와 비교 압박 우려로 12/7 범위에서 제외하고 출시 후 검토
- **매주 열어 볼 이유:** 주간 리포트와 "이번 주 저녁 질문"으로 학부모의 매주 리포트 열람을 유도
- **쌓일수록 커지는 가치:** 생각 기록과 돌아보기가 쌓일수록 지난달과 비교할 수 있어 성장 기록의 가치가 커짐
- **중도 이탈 대응:** 미션은 10분 안팎으로 짧게 유지하고 주 3회를 목표로 함

  쉬었다 돌아온 아이에게는 지난 생각을 이어 가는 "복귀 미션"을 제공하고 학부모에게 주간 알림을 발송하며, 효과는 월 해지율과 주당 미션 완료 횟수로 확인
- **가격 장치:** 연간 결제 할인, 형제 추가 할인

3.11 규제

만 14세 미만 아동의 개인정보 처리 시 법정대리인의 동의를 받고 동의 여부를 확인해야 함(개인정보 보호법 제22조의2 제1항)

사고뭉치는 결제자인 학부모가 가입 주체가 되는 구조라 동의 절차를 자연스럽게 포함할 수 있어 오히려 유리함

4. 시스템 구성 기획

12/7 배포 **완성본 기준**, 데모 계정만 운영하고 결제는 연동하지 않음

4.1 전체 구성도

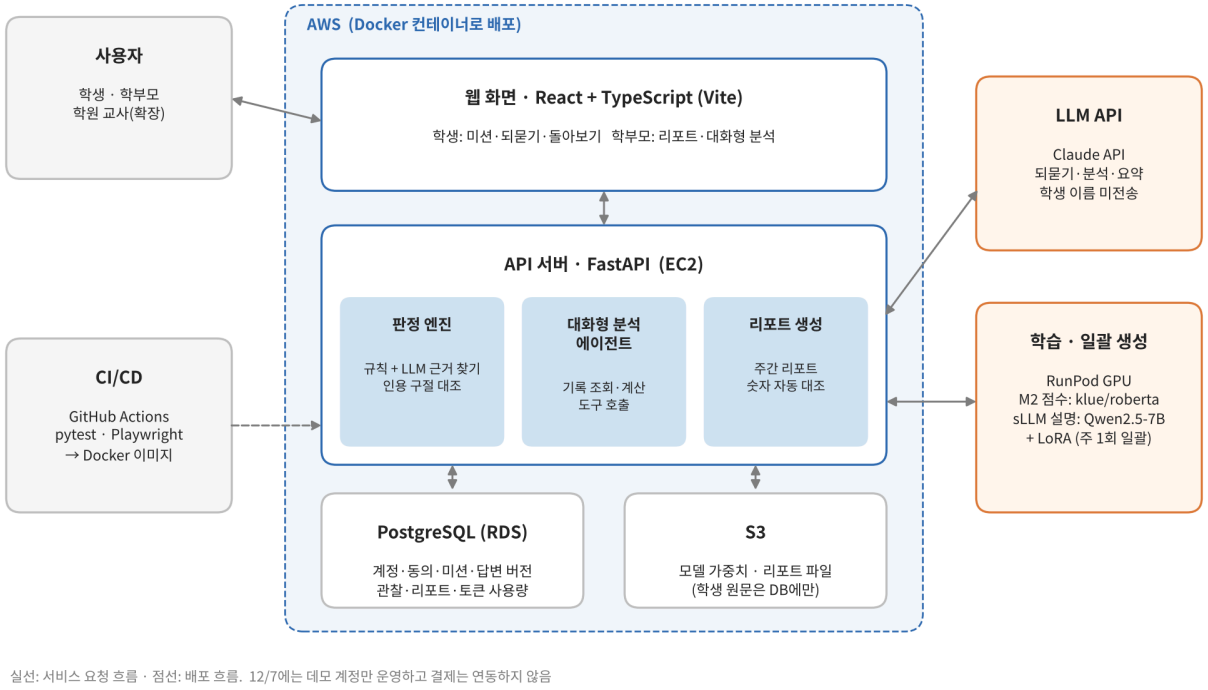


그림 6. 사고뭉치 시스템 구성도

4.2 학생 미션 한 번의 흐름

순서	내용
1	미션 장면(애니메이션)과 질문을 보고 답을 쓰거나 고름, 막히면 생각 열기 질문(?)과 메모장(✎)을 활용
2	판정: 문항 종류(정답이 있는 문항 / 정답이 여러 개인 문항)에 따라 다르게 판정하고(아래 표), 서술·논술은 채점 기준표의 요소별로 LLM이 아이 답의 구절을 찾고 코드가 그 구절이 답에 실제로 있는지 확인
3	대화형 되묻기: 결과에 따라 **“한 걸음 더”** / **“더 말해 보기”** / **“다시 살펴보기”**로 이어지며, 빠진 생각 요소가 채워지거나 학년별 최대 횟수(초1~2 1회, 초3~4 2회, 초5~중3 3회)에 이를 때까지 되묻기를 반복함, 막히면 힌트를 단계별로 제공(장면 다시 보기 → 비교 질문 → 예시)하고, 근거가 없으면 판정하지 않고 보류
4	아이가 생각을 다 낸 뒤에만 정답·예시 답과 "들어가면 좋은 생각" 체크가 열리고, 처음 답과 마지막 답을 나란히 보여 준 뒤 돌아보기를 남김

순서	내용
5	다음 미션 추천: 자주 빠지는 생각 요소에 맞춰 다음 미션 후보 2개를 제시하고 아이가 하나를 고름(3.10 ③), 같은 성취기준 안에서는 쉬운 미션에서 어려운 미션 순으로 제시하며 추천 이유를 학부모 리포트에 표시함 (예: '다른 관점 고려'가 3회 연속 빠지면 따져 보기 미션 추천, 규칙 기반)

문항 종류별 판정과 진행

구분	정답이 있는 문항	정답이 여러 개인 문항
예	규칙 찾기, 순서 맞추기, 원인 찾기, 수학 최종 답	분류 기준, 내 생각과 이유, 새로 만들기
판정	정답표(규칙)로 확인	고른 답이 아니라 이유를 봄: ① 기준(이유)을 말했는지 ② 그 기준이 보기의 사실에 맞는지
맞았을 때	찾은 방법을 짚어 주는 말 + "어떻게 알았어?" (답하지 않아도 됨) 예: "색이 두 번씩 바뀌는 규칙을 찾았구나! 어떻게 알았어?"	찾은 기준을 짚어 주는 말 + 다른 기준·다른 생각 보여 주기
다를 때	"아직 맞지 않아"와 단서(힌트) → 다시 고르기 → 그래도 다르면 정답과 설명을 보여 주고 마침 예: "아직 규칙과 맞지 않아. 구슬 색이 어떻게 바뀌는지 다시 볼까?"	틀림 없음, 이유가 없거나 사실이 틀릴 때만 되묻기
어울리는 생각 유형	분석하기(원인), 문제 해결하기(규칙·순서), 기초 사고력	따져 보기, 새로 만들기, 돌아보기

- 초1~2는 성취기준 목표가 생각·느낌 표현과 쓰기 흥미에 있으므로([2국01-04], [2국03-02]) 되묻기를 1회로 줄이고, 이유는 고르거나 말로 하며 보호자 받아쓰기로 입력함
- 초1~2 판정 결과는 점수 없이 학부모 리포트 기록에만 쓰고, 12/7 시범 미션 5개는 정답형과 열린형을 섞어 구성함
- 피드백은 맞고 틀림을 알려 주되 푸는 과정의 단서를 함께 주고, 막연한 칭찬 대신 잘한 점을 짚어 줌 (과정 단서는 효과적, 사람 자체에 대한 칭찬은 효과가 거의 없음: Hattie & Timperley, 2007)
- 이유 판정의 정확도는 5.3 (5)와 같은 방식으로 검증하고, 기준에 미달한 미션은 판정하지 않고 기록만 함

4.3 사고 과정 기록 방식

사고뭉치는 생각 자체가 아니라 생각이 겉으로 드러난 흔적을 기록함

최종 원문과 점수만 저장하면 결과물 기록에 그치므로, 미션 한 번을 네 시점으로 나누어 각 시점의 흔적을 함께 저장함



그림 7. 미션 한 번의 사고 과정 기록 (네 시점과 저장 위치)

시점	저장하는 것	보여 주는 과정	구현 상태
① 쓰기 전	메모장 초안, 생각 열기 질문 사용 여부	생각의 출발점, 도움을 받았는지	MVP 구현
② 쓰는 동안	고친 횟수, 지운 글자 수, 오래 멈춘 구간, 붙여넣기 여부 (집계값만)	고민한 지점, 직접 쓴 흔적	추가 개발
③ 되묻기 후	처음 답과 고친 답(덮어쓰지 않고 별도 버전), 받은 질문, 새로 확인된 생각 요소	질문을 받고 생각이 어떻게 바뀌었는지	MVP 구현
④ 마친 뒤	돌아보기(어려웠던 점, 달라진 점)	자기 생각을 점검하는 과정(메타인지)	MVP 구현

- **근거:** 글쓰기 연구에서는 키 입력 기록(keystroke logging)으로 멈춤·수정 같은 쓰기 과정을 분석함(Leijten & Van Waes, 2013), ②는 이 방식을 서비스 규모에 맞게 줄여 원문 키 입력 없이 집계값만 저장함
- **리포트 표시:** 원본 로그가 아니라 "3번 고쳐 씀, 질문을 받고 근거 1개를 더함"처럼 요약만 제시함
- **해석 한계:** 붙여넣기가 없어도 다른 기기의 답을 보고 옮겨 쓸 수 있으므로, ②는 직접 썼다는 증명이 아닌 참고 흔적으로만 쓰고 리포트에서도 "직접 썼다"고 단정하지 않음

- **개인정보:** ②의 추가 수집 항목은 법정대리인 동의 항목에 포함함

4.4 학부모 화면 흐름

순서	내용
1	학부모가 가입하고 자녀를 등록하며, 이때 법정대리인 동의를 받고 동의 기록을 저장
2	주간 리포트 확인, 리포트는 기록에서 자동 생성(숫자 근거(분모·계산식 포함), 다섯 가지 생각 유형, 되묻기 전후 변화, 아이 원문 인용, 이번 주 저녁 질문)
3	"질문을 받고 뭐가 달라졌어?"처럼 리포트에 질문하면 에이전트가 학습 기록을 도구로 조회·계산해 답하고, 답 속 숫자·인용은 실제 기록과 자동 대조 후 제시

4.5 기술 스택

구분	사용 기술	역할
프론트엔드	React, TypeScript, Vite	학생 미션 화면, 학부모 리포트·대화 화면, 반응형 UI
백엔드	FastAPI (Python), Pydantic	REST API, 인증, 미션·답변·리포트 API, API 명세
AI 기능 연동	FastAPI 내부 모듈	판정 엔진, 대화형 분석 에이전트, 리포트 계산
DB	Alembic, SQLAlchemy, PostgreSQL, pgvector (MVP는 SQLite, 배포는 PostgreSQL)	답변 버전·관찰·도움·돌아보기·리포트 저장, 스키마 마이그레이션
LLM	Claude API	판정 근거 찾기, 되묻기, 대화형 분석(도구 호출), 리포트 요약
학습 모델	PyTorch, Hugging Face Transformers, PEFT(LoRA)	M2 점수(klue/roberta), sLLM 설명(Qwen2.5-7B-Instruct + LoRA)
학습·일괄 생성	RunPod GPU	모델 학습, 설명 문장 주 1회 일괄 생성
평가·시각화	scikit-learn(QWK), pandas, matplotlib	사람-AI 채점 일치도, 모델 평가 결과 시각화
인프라	Docker, AWS(EC2, RDS, S3), GitHub Actions	컨테이너 배포, CI/CD

구분	사용 기술	역할
테스트·운영	pytest, Playwright	백엔드·판정 단위 테스트, 화면 E2E 테스트, 통합 테스트, 모니터링·장애 대응
저학년 입력 (확장)	고르기, 보호자 받아쓰기, STT 시범	아동 음성은 저장하지 않음

4.6 데이터 저장 구조

테이블	저장하는 것
학부모·동의	학부모 계정, 법정대리인 동의 일시·항목
학생	자녀 정보(가명), 학년, 연결된 학부모
미션	미션 내용, 성취기준 코드, 채점 기준표 버전
답변	처음 답과 고친 답을 덮어쓰지 않고 버전별로 저장
쓰기 과정	고친 횟수, 지운 글자 수, 멈춘 시간, 붙여넣기 여부 (원문 키 입력은 저장하지 않고 집계값만 저장)
관찰·도움·돌아보기	판정 결과와 근거 구절, 되묻기 질문, 생각 열기 질문·받아쓰기 사용, 아이의 돌아보기
리포트·대화	주간 리포트, 저녁 질문, 학부모 질문과 에이전트 답, 숫자·인용 대조 결과
LLM 사용량	호출 종류별 입력·출력 토큰 수 (학생 ID·답변 내용은 남기지 않음)

4.7 보안·운영 원칙

- **키 관리:** API 키는 환경 변수와 GitHub Secrets에만 보관하고 저장소에 올리지 않음
- **개인정보:** 학생 이름은 LLM API로 전송하지 않으며, 12/7 배포는 데모 계정만 사용하고 실제 아동은 가입하지 않음
- **비용 관리:** LLM 호출마다 토큰 사용량을 기록해 3.9의 원가를 실제 값으로 산출
- **DB 백업:** RDS 자동 백업(보존 7일, 시점 복원)과 배포·스키마 마이그레이션 전 수동 스냅샷을 사용하고, 주 1회 pg_dump를 S3에 보관하며 12/7 전 복원 리허설을 1회 실시함

- **테스트 시나리오:** 단위 테스트(pytest)·화면 테스트(Playwright)와 별도로 실제 사용 시나리오 3개를 처음부터 끝까지 검증함

  ① 학생이 미션을 풀고 되묻기 후 답을 고침 → 답변 버전·쓰기 과정 저장 확인

  ② 주간 리포트 자동 생성 → 숫자·인용 대조 통과 확인

  ③ 학부모가 리포트에 질문 → 에이전트 답의 숫자·인용이 실제 기록과 일치하는지 확인
- **인프라 범위:** 12/7 범위는 Docker + AWS(EC2, RDS)로 운영하고 Kubernetes는 쓰지 않음(구성원 학습·운영 부담 대비 12/7 데모에 필요한 이점이 적음), 확장 시 자체 구축 대신 관리형(EKS)과 비교 후 결정

5. 모델링 계획

12/7 필수 학습 모델은 M2(글 점수, klue/roberta)로 하고, 그 위에 sLLM 설명 모델을 얹는 구조로 설계 최종 확정은 11/1에 M1(수학 풀이)과 빠른 기준선 비교 후 결정하며, 실시간 되묻기·대화형 분석은 학습 없이 LLM이 담당

sLLM 도입은 과정 필수 요건이 아님을 확인했으므로(10/23 멘토링) 설명 모델은 확장으로 두고, 12/7까지는 M2 점수 모델을 기준선과 비교하는 데 집중함

모델	입력 → 출력	학습 데이터	서비스에서 쓰는 곳	상태
M2 점수 (필수)	지시문 + 학생 글 → 항목별 1~5점 (과제수행 충실성, 설명의 명료성·구체성·적절성 등)	AI Hub 71818 서술형(4만 건)·71819 논술형(2만 건), 전문가 2인 점수	초5~중3 서술·논술 미션의 "AI 관찰" 점수, LLM 관찰과 교차 확인 (초3~4는 LLM 관찰만, 초1~2는 정답표·이유 체크만)	데이터 확보, 구조 확인
M2 설명 (sLLM, 확장)	글 + M2 점수 → 그 점수에 대한 설명 문장	71818 전문가 피드백 문장 (총체·항목별)	학부모 리포트 설명 (주 1회 일괄 생성)	설계 RunPod에서 LoRA 학습 예정
M1 풀이 점검 (비교 후보)	문제 + 정답 + 풀이 → 정답 여부·필수 과정 실수·계산 실수	AI Hub 71716 손글씨 풀이 라벨	수학 풀이 점검(시범)	파이프라인 완성, 초기 실험

※ klue/roberta는 Hugging Face 모델 카드에 라이선스가 표기되어 있지 않으므로(KLUE 저장소는 CC BY-SA 4.0) 사용 조건을 확인한 뒤 확정하며, MIT 라이선스인 xlm-roberta-base를 기준선 비교에 함께 포함함

5.1 왜 BERT 계열로 점수를 내고, sLLM은 설명만 맡기나

- 단답형 채점 비교 연구에서 지도학습 BERT가 QWK 0.74 / 0.87 / 0.94, 파인튜닝한 GPT-3.5가 0.61 / 0.81 / 0.83으로 나타남(ASAP·MindReading·Powergrading 순, BEA 2024), 에세이 채점에서도 학습시킨 인코더가 최고 약 0.85(ELECTRA-large)로 학습 없는 GPT-5(0.73)보다 높게 나타남 (arXiv 2510.27131), 두 연구 모두 영어 데이터라 한국어는 직접 확인 예정

- sLLM의 장점은 설명 문장 생성이므로 점수를 받아 설명만 작성하게 해 점수와 설명이 어긋나지 않도록 함
- 71818 피드백은 "부족합니다" 같은 평가 말투이므로 학부모 리포트에만 사용하고, 아이에게 하는 되묻기는 질문 은행과 LLM이 담당

5.2 평가 계획

데이터 분할	지시문(문항) 단위로 분할, 71716은 AI Hub Training·Validation이 문항 그룹을 공유해(초5 기준 339/339 그룹) 그룹 단위로 재분할
기준선	다수 클래스 / 규칙 / TF-IDF+로지스틱 / xlm-roberta-base(파인튜닝) / LLM(학습 없음) / 전문가 2인 간 일치도(상한선)
지표	점수: QWK·균형정확도, 과대·과소 판정률 / 설명: 인용 대조·금지어 통과율, 팀원이 50개를 읽고 사실성·말투 평가
초기 실험 (M1, 초5)	정답 여부 균형정확도: TF-IDF+로지스틱 0.725, 규칙(정답 숫자가 풀이에 있음) 0.718. 단서가 약해 M2를 1순위로 둔 근거
생각 유형 판정 검증	답안 100개를 사람 2인이 독립 표시, 사람-사람·사람-LLM 카파 계수 비교, 기준 미달 유형·미션은 판정 보류 (5.3)
되묻기 검증	아이 답과 되묻기 문장 100~200쌍을 팀원 2인이 적절성 라벨링(NCTE Transcripts·TalkMoves의 대화 분류 체계 적용), 라벨 일치도(카파) 확인
에이전트·리포트 검증	학부모 예상 질문 50개(가상 학생 기록에서 직접 센 정답)의 정답 일치율·숫자·인용 대조 통과율, 자동 생성 리포트 20개의 문장별 사실 오류율
활성화 조건	모델 학습 시작 전(11/1 모델 확정 전)까지 팀이 허용 기준(생각 유형 판정 카파, M2 QWK)과 비교할 기준선을 먼저 정하고, 11/22 활성화 판단에서 기준을 넘은 범위만 서비스에 적용하며 기준 미달 시 평가 보고서로 제출

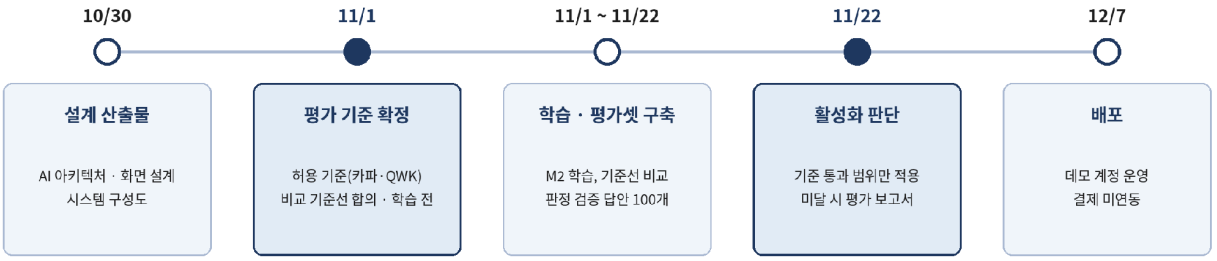


그림 8. 모델 평가 기준 확정과 활성화 일정

5.3 생각 유형 평가 기준과 검증

생각 유형을 분류·평가하는 단일 국제 표준은 없음

따라서 ① 각 유형의 평가 요소는 공신력 있는 틀(AAC&U VALUE 루브릭, 블룸 개정 분류)에서 가져오고, ② 판단 문장은 한국 공식 기준인 2022 개정 성취기준·성취수준에 연결하며, ③ 사람 채점과의 일치도로 직접 검증함

- **유형별 평가 요소:** 미국대학협회(AAC&U) VALUE 루브릭을 따름, 여러 대학 교수진이 개발해 3,000여 개 캠퍼스가 채택했으며 비판적·창의적 사고, 문제 해결 등 16종이 공개됨
  채점자 보정 없이는 점수가 정확히 일치한 경우가 약 1/3이었고 보정 훈련 후 일치도가 높아졌다는 보고가 있어, (5)에서 일치도를 직접 검증함
- **학년 수준:** VALUE 루브릭은 대학생용이므로, 미션마다 연결한 2022 개정 교육과정 성취기준과 한국교육과정평가원 성취수준 문장으로 학년에 맞게 바꿈

(1) 유형별 평가 요소

생각 유형	근거	평가 요소 (초·중 수준)	연결 성취기준 예
분석하기	블룸 개정 분류 "분석" (Anderson & Krathwohl, 2001)	① 원인·특징·관계를 말함 ② 까닭을 이어 설명함	[6과07-02] 온도 변화를 관찰하고 그 원인을 추리
따져 보기	VALUE 비판적 사고: 학생의 입장, 근거, 맥락과 가정의 영향	① 자기 주장 ② 근거 ③ 다른 관점·예외 고려	[6국01-02] 근거가 타당한지 평가 / [9국03-03] 타당한 근거로 주장하는 글
새로 만들기	VALUE 창의적 사고: 혁신적 사고, 연결·종합·변형	① 기존과 다른 생각 ② 다른 것과 연결·변형 ③ 왜 나은지 설명	[6도03-02] 공정한 규칙을 직접 고안
문제 해결하기	VALUE 문제 해결: 문제 정의, 전략 찾기, 결과 평가	① 문제가 무엇인지 말함 ② 방법을 세움 ③ 결과를 확인함	[6수03-14] 넓이를 구하는 방법을 추론하고 문제 해결
돌아보기	VALUE 평생학습의 성찰 / 메타인지 (Flavell, 1979)	① 자기 생각 과정을 말함 ② 무엇이 바뀌었는지 말함	[6국03-05] 쓰기 과정을 점검·조정하며 고쳐 씀

※ 연결 성취기준은 교육부 고시 제2022-33호 초등·중학교 교육과정 기준이며, [6국01-02]는 듣기·말하기 영역 성취기준임

(2) 판정 방법

- 미션마다 위 요소를 연결 성취기준의 성취수준 문장에 맞춰 2~3개로 구체화함 (예: [6과07-02] → "온도가 높은 쪽에서 낮은 쪽으로 열이 이동한다는 원인을 말함")
- LLM은 요소마다 아이 답에서 해당 구절을 찾고, 코드는 그 구절이 아이 답에 글자 그대로 있는지 확인함
- 결과는 요소별 있음/없음 + 근거 구절이며, VALUE 루브릭의 4단계 점수는 사용하지 않음 (초·중 학생 답에 대한 LLM 단계 판정 신뢰도가 확인되지 않음)

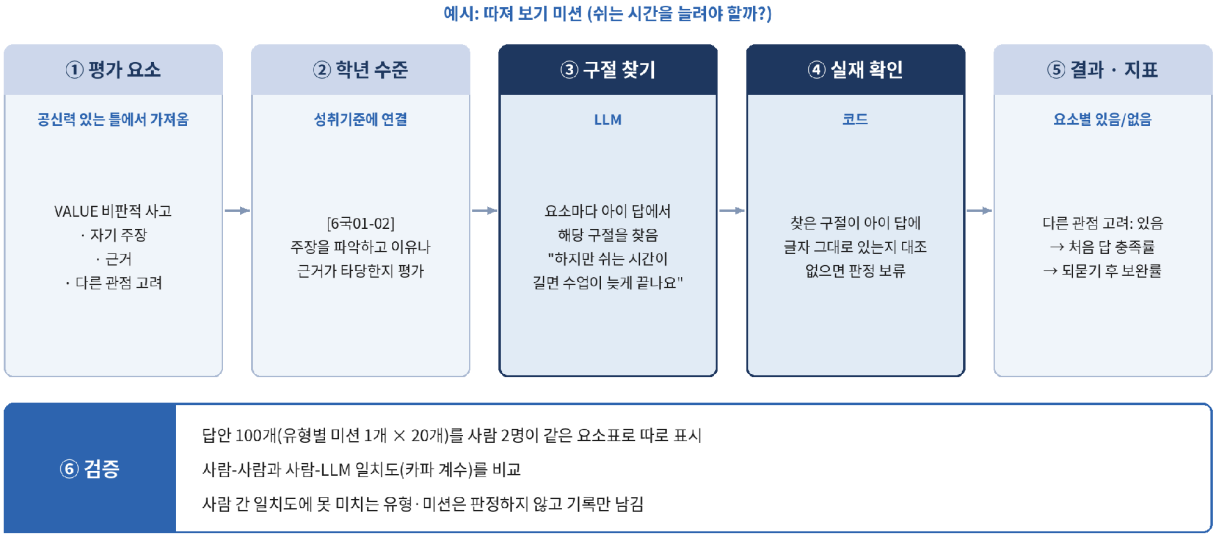


그림 9. 생각 유형 판정 흐름 (따져 보기 미션 예시)

(3) 계산

지표	계산식
처음 답 충족률 (핵심)	처음 답에서 확인된 요소 수 ÷ 미션 전체 요소 수
되묻기 후 보완률	고친 답에서 새로 확인된 요소 수 ÷ 처음 답에서 빠진 요소 수
논증 요소 충족률	처음 답에 주장·근거·반론이 모두 있는 답 수 ÷ 논술 미션 답 수
논술 점수	M2가 산출한 8개 항목(1~5점)의 학년군별 평균
근거·까닭 연결어 변화 (보조)	고친 답의 근거 구절·연결어("왜냐하면·때문에·그래서" 등) 수 − 처음 답의 수

(4) 해석

- 같은 생각 유형·같은 학년군 미션끼리만 월별 비교하고, 같은 성취기준의 기준 미션을 처음과 4주 뒤에 풀게 해 변화를 봄
- 분모가 5 미만이면 비율을 표시하지 않음
- 학부모에게는 점수·등급·또래 비교가 아닌 요소와 아이 구절로 제시함
  예: "따져 보기에서 '다른 관점 고려'가 처음 답에 나타난 미션이 지난달 5개 중 1개 → 이번 달 5개 중 3개 ('하지만 쉬는 시간이 길면 수업이 늦게 끝나요.')"
- "사용 기간 동안의 변화"까지만 제시하고, "서비스 때문에 향상됐다"는 주장은 비교 집단이 필요하므로 출시 후 과제로 둠

(5) 검증

- 생각 유형별 대표 미션 1개씩, 총 5개 미션의 답안 100개(미션당 20개)를 사람 2명이 같은 요소표로 독립 표시함. 검증 결과는 해당 미션과 학년군 범위에서 해석하며, 다른 미션에 적용할 범위와 추가 검증 필요 여부는 별도로 결정함
- 사람-사람과 사람-LLM 일치도(카파 계수)를 비교하고, 사람 간 일치도에 미치지 못하는 유형·미션은 판정하지 않고 기록만 함
- AI Hub 71818 전문가 채점 답안 30~50개를 팀원이 동일한 글쓰기 루브릭(8개 항목, 1~5점)으로 채점하고 전문가 점수와의 일치도(QWK)를 확인해 채점 기준을 맞춤, 기준을 맞춘 팀원이 자체 미션 답안을 같은 방식으로 채점해 M2 점수와의 일치도를 측정함
- 생각 요소(있음/없음) 판정은 전문가 라벨이 없으므로 팀원 2인의 독립 판정으로 별도 검증하며, 팀원 채점이 전문가 점수와 충분히 일치하지 않으면 팀원 점수는 사용하지 않고 M2 검증은 AI Hub 평가용 데이터의 전문가 점수로만 수행함

(6) 한계

- 다섯 유형으로 나눈 묶음 자체는 팀이 구성한 틀임, 개별 요소는 공신력 있는 근거에 기대지만 다섯 가지 분류가 표준이라고 주장하지 않음
- VALUE 루브릭은 대학생용이므로 초·중 적용은 성취기준 연결과 (5)의 일치도 검증으로만 뒷받침함
- MVP 검증 답안은 팀원이 작성한 예시 답안 기준이며, 실제 아동 답안으로 검증하는 것은 출시 후 과제로 둠

6. 데이터 수집 전략

학습·평가용 AI Hub 데이터 4종은 모두 다운로드 완료, 서비스 미션은 전부 자체 제작 AI Hub

문항·답안·피드백 원문은 서비스 화면에 사용하지 않음

데이터	규모	라벨	용도	상태
71818 서술형 글쓰기 평가	4만 건 (초5·초6 각 1만, 중1·중2 각 7천, 중3 6천), 국어·사회·과학·수학	총체적 평가 1~5점 + 분석적 평가 8개 항목 1~5점, 채점 전문가 2인 + 피드백 전문가 1인	M2 점수·설명 학습 (필수)	다운로드 완료, 초5 검증 데이터 구조 확인
71819 논술형 글쓰기 평가	2만 건 (초5~중3), 국어·사회·과학	71818과 같은 8개 항목 + 피드백	M2 논술형 보강	다운로드 완료
71716 수학 과목 자동 풀이	문항 34,392개 (초3~고), 학생 손글씨 풀이 18만 3,085건 (초5 풀이 25,305건은 팀 EDA 집계)	정답 여부, 필수 과정 실수 수, 계산 정확도	M1 비교 후보	다운로드·EDA·전처리 완료
545 에세이 글 평가	50,413건 (초4~고3)	최대 11개 항목, 전문가 3인	참고 ("참신성" 정의 확인 전 창의성 라벨로 쓰지 않음), 고등학교 논술 평가 확장 시 검토 (초4~고3 포함)	다운로드 완료

6.1 수집 방법과 처리

순서	내용
1	AI Hub 승인 후 파일 다운로드(웹·API 키), 원천 이미지는 사용하지 않고 라벨링 zip만 사용하며 71716은 손글씨 이미지(1~2GB 묶음)를 제외하고 라벨 zip 16개로 충분함

순서	내용
2	스크립트가 zip을 풀지 않고 바로 읽어 EDA → 학습용 표 → 문항(그룹) 단위 분할을 생성하며, 71716의 LaTeX OCR 텍스트는 평문으로 변환
3	서비스 기록(답변·관찰·도움·돌아보기)은 PostgreSQL에 버전별로 저장하며, 이 기록이 대화형 분석 에이전트와 자동 리포트의 데이터가 됨
4	채점 검증용으로 팀원이 미션별 예시 답안 20~30개를 작성하고, 2명이 따로 채점해 사람-사람, 사람-AI 일치도를 측정

6.2 미션 제작 방법

미션은 서비스의 핵심 콘텐츠 데이터이므로 아래 절차로 제작하며, 모든 미션은 2022 개정 교육과정 성취기준 코드 1개 이상에 연결함

순서	내용
1	**성취기준 선택**: 성취기준 표(초1~중3 790개, 교육부 고시 원문과 평가원 성취수준에서 추출)에서 학년군·과목·생각 유형에 맞는 성취기준을 고름 (예: [6과07-02] "그 원인을 추리" → 분석하기)
2	**초안 생성**: 성취기준 문장과 성취수준 문장을 입력해 LLM이 미션 초안(장면·질문·생각 요소 2~3개·질문 금지어·다른 정답·예시 답)을 정해진 형식으로 작성함
3	**자동 검사**: 필수 항목, 성취기준 코드 존재 여부, 질문 속 정답·금지어 노출(판정 엔진의 질문 검사 재사용), 학년별 질문 길이를 확인하고 통과하지 못하면 사유를 붙여 다시 생성함
4	**검수·확정(APM)**: 학년·내용·행동(성취기준 동사)이 미션과 맞는지 확인해 승인·수정·반려하고, 생성 방식('LLM 초안 + 팀 검수')과 상태(초안 → 검토 완료 → 공개)를 기록함
5	**시범 풀이**: 팀원이 해당 학년 수준의 답 3~5개로 판정을 실행해 생각 요소가 잡히는지, 되묻기가 정답을 드러내지 않는지 확인하고 필요하면 생각 요소를 고침

- 현재 MVP 미션 10개는 성취기준 코드가 비어 있으므로 위 1·4단계에 따라 코드를 연결하고 학년을 다시 검토함 (예: 컵 물방울 미션은 내용상 초3~4 [4과10-02]에 가까움)
- 미션 초안 생성은 최성욱, 검수·확정은 김동섭(APM)이 담당함 (7장)

7. 역할분담(R&R)

6명을 PM·Ops, APM·Infra, LLM·ML/DL, Backend·DB, LLM·ML/DL·Backend, ML/DL·Frontend로 구성함

가장 업무량이 많은 영역은 APM의 미션 제작(현재 10개 → 12/7까지 35개, 최종 최소 64개)이고 결과가 가장 불확실한 영역은 모델이며, LLM은 서비스 안에서 실시간으로 동작하는 판정·에이전트(최성욱)와 학습시키는 sLLM·스코어링 모델(김재현)로 나눠 담당함

미션 초안은 LLM으로 생성하고 APM이 검수·확정하며, 예시 답안 작성과 사람 채점(사람 2인 독립 표시)은 판정·모델 개발과 분리하기 위해 김태윤·황수빈이 분담함

인원	담당	맡을 일
김태윤	PM, Ops	**[PM]** 일정·범위 관리, WBS·회의 운영, 산출물 작성, 발표, 모델 평가 기준 합의(학습 전) **[Ops]** 통합 테스트, 서비스 모니터링, 장애 대응 **[검증]** 예시 답안 작성·사람 채점(2인 독립 표시)
김동섭	APM, Infra	**[APM]** 미션 제작·성취기준 연결, 성취수준 기반 채점 기준표, LLM 미션 초안 검수·확정 **[Infra]** Docker 이미지, AWS 배포 환경, CI/CD
김재현	LLM, ML/DL	**[LLM]** sLLM 설명 모델 학습 및 평가, 설명 문장 품질 검사 **[ML/DL]** 스코어링 모델 개발 및 검증, 모델 서빙 API
최인영	Backend, DB	**[Backend]** FastAPI 서버, API 명세, 백엔드 테스트 **[DB]** PostgreSQL 스키마 설계 및 마이그레이션
최성욱	LLM, ML/DL, Backend	**[LLM]** 프롬프팅 엔지니어링(미션 초안 생성 포함), 성취수준 기반 판정, 대화형 분석 에이전트 설계 및 검증, LLM 출력 평가 **[ML/DL]** 답변 판정 파이프라인 개발, 판정 결과 검증 및 분석 **[Backend]** 판정 엔진·에이전트·리포트 계산 모듈, AI 기능 API를 FastAPI에 연동
황수빈	ML/DL, Frontend	**[ML/DL]** 채점 일치도 계산, 모델 평가 결과 시각화 **[Frontend]** 반응형 UI/UX 개발 **[검증]** 예시 답안 작성·사람 채점(2인 독립 표시)

출처

- 뉴시스(다음) – 서울 학생 생성형 AI 사용 조사
- 헤럴드경제 – 2024 학업성취도 평가
- 다음 – 2025 학업성취도 평가
- 교육을 비추다 – 하이러닝 AI 서·논술형 평가
- 뉴시스 – 2025 사교육비 조사
- 헤럴드경제 – 2025 사교육비 조사 학교급별 결과
- 괜찮은뉴스 – 2025 사교육비 조사 과목별 분석(일반교과 참여율)
- 한국교육개발원 – 2026년 교육기본통계 조사 결과
- 성인지통계 – 사설학원수, 강사수 및 수강인원(한국교육개발원 교육통계연보)
- 대학저널 – 충북 에듀테크 소프트랩
- 머니투데이 – 키위런 대교 솔루니 공급
- 써봄 공식 누리집
- Anthropic – Claude API 가격표
- 이투데이 – 한국 성인 언어능력 OECD 평균 미달 (PIAAC 2주기, 2024.12.10.)
- 국가법령정보센터 – 개인정보 보호법
- 국가데이터처, 교육부, 「초중고사교육비조사」, 2025, 학교급별 사교육 참여율 (KOSIS 국내통계 > 주제별 통계 > 교육·훈련 > 초중고사교육비조사 > 특성 및 과목별 사교육 참여율 > 학교급별 사교육 참여율, 2026.10.23. 참조)
- 경기도교육청 – 경기교육 서·논술형 평가시스템 이해자료 (중등 개통 2025.7.2.)
- Leijten & Van Waes (2013) – Keystroke Logging in Writing Research: Using Inputlog to Analyze and Visualize Writing Processes
- AAC&U VALUE Rubrics (16종 목록)
- AAC&U – How Reliable Are the VALUE Rubrics?
- OneHE – VALUE 루브릭 신뢰도 연구 정리
- VALUE Rubrics 개발·검증 설명 (PhysPort)
- Creative Thinking VALUE Rubric
- Problem Solving VALUE Rubric
- Foundations and Skills for Lifelong Learning VALUE Rubric
- Revised Bloom's Taxonomy (Anderson & Krathwohl, 2001)
- Flavell (1979) – Metacognition and cognitive monitoring

- Doewes, Kurdhi & Saxena (2023) – Evaluating QWK as the Standard Performance Metric for AES
- Demszky & Hill (2023) – The NCTE Transcripts: A Dataset of Elementary Math Classroom Transcripts (BEA 2023)
- Suresh et al. (2022) – The TalkMoves Dataset: K-12 Mathematics Lesson Transcripts Annotated for Teacher and Student Discursive Moves (LREC 2022)
- Hugging Face – klue/roberta-base 모델 카드 (라이선스 미표기, 2026.10.25. 확인)
- KLUE-benchmark GitHub 저장소 (CC BY-SA 4.0)
- Hugging Face – FacebookAI/xlm-roberta-base (MIT)
- Hattie & Timperley (2007) – The Power of Feedback (Review of Educational Research)
- 뉴시스 – 약술형 논술 모집 4년새 37%↑ (이투스 교육평가연구소 분석, 2026.8.6.)
- NEIS 교육정보 개방 포털 – 학원교습소정보 (등록 교습비, 2026.10.23. 조회)
- 국가데이터처 – 2025년 초중고사교육비조사 결과 보도자료 (PDF)
- 한국경제TV – 학부모 AI 숙제 인식 조사 ((주)깔로, 2026.8.6.)
- 전자신문 – 학부모 67.9% AI 학원관리 서비스 활용 의향 (대교에듀베이션, 2025.11.19.)
- Common Sense Media – The Dawn of the AI Era: Teens, Parents, and the Adoption of Generative AI (2024.9.18.)
- 파이낸셜뉴스 – 2027년 교육부 예산안 117조 5,962억 원 (2026.9.1.)